

Natural Language Processing

Aufgabenblatt V Hackathon

Fachhochschule Graubünden
Bachelor of Science FHGR in Computational and Data Science

Vorname, Nachname: _____

Studiengang	Bachelor of Science FHGR in Computational and Data Science
Modul	Natural Language Processing
Kurs	NLP Foundations: From Classical Methods to Large Language Models
Kürzel	cds1091
Dozent	Prof. Corsin Capol

1. Ziel der Aufgabe

Ziel dieser Aufgabe ist die Entwicklung eines Systems, das natürlichsprachliche Fragen zu einem RDF-Graphen automatisch in SPARQL-Queries übersetzt. Ihre Lösung soll die generierten Queries auf dem passenden Graphen ausführen und die Resultate in einem klar definierten JSON-Format zurückgeben.

Die Aufgabe ist ausdrücklich als **Prototyp-Challenge** angelegt. Es wird **keine vollständige Produktionslösung** erwartet. Der Umfang soll so gewählt werden, dass die Aufgabe **innerhalb von maximal vier Lektionen** realistisch bearbeitet werden kann.

2. Datengrundlage

Es werden zwei RDF-Graphen bereitgestellt:

- `superhero_universe.ttl`
- `recipes_100.ttl`

Zusätzlich erhalten Sie:

- ein **Dev-Set** mit Fragen und Referenzqueries,
- ein **Hidden Test-Set** mit Fragen für die finale Bewertung,
- eine kurze Ontologie-/Schema-Übersicht,
- optional Basis-Code-Templates.

Das **Dev-Set** dient zur Entwicklung, zum Prompting, zum Debugging und zur Fehleranalyse. Das **Hidden Test-Set** dient ausschliesslich der finalen Bewertung. Goldqueries und Goldresultate des Hidden Test-Sets bleiben bei der Lehrperson.

3. Technischer Rahmen

Die Bearbeitung kann erfolgen auf:

- DGX Spark Workstations,
- lokalen Rechnern,
- FHGR-GPU-Servern.

Als empfohlene Ausgangsbasis kann **LLM Studio** verwendet werden. Alternativ dürfen auch eigene Python-Setups und eigene Pipelines eingesetzt werden, sofern diese reproduzierbar sind und innerhalb des vorgegebenen Zeitrahmens umsetzbar bleiben.

4. Erwartete Leistung

Entwickeln Sie in Ihrer Gruppe ein Verfahren, das für jede Frage aus dem Test-Set automatisch:

1. die Frage verarbeitet,
2. eine SPARQL-Query erzeugt,
3. diese Query auf dem passenden RDF-Graphen ausführt,
4. und das Resultat in der geforderten JSON-Struktur speichert.

Ihre Lösung soll auf **beiden Graphen** funktionieren.

5. Methoden

Sie dürfen frei entscheiden, welche Methoden Sie verwenden. Erlaubt sind insbesondere:

- Prompt Engineering,
- Few-shot Prompting,
- Ontologie- oder Schemabeschreibung im Prompt,
- mehrstufige Pipelines,
- Query-Reparatur oder Validierung,

- mehrere LLM-Aufrufe pro Frage,
- regelbasierte Vorverarbeitung,
- Candidate Generation und Reranking,
- sowie weitere NLP-Techniken nach Ihrer Wahl.

Dazu können zum Beispiel auch Verfahren wie NER, NED, Entity Linking, Schema Linking oder andere Ansätze verwendet werden. Es ist bewusst freigestellt, welche NLP-Techniken oder Pipeline-Bausteine Sie einsetzen.

Nicht zulässig sind:

- manuelle Nachbearbeitung einzelner Testfragen,
- hartkodierte Spezialfälle für konkrete Testfragen,
- Nutzung der Goldqueries oder Goldresultate des Hidden Test-Sets.

6. Empfohlener Arbeitsumfang über vier Lektionen

Ein sinnvoller Rahmen für die vier Lektionen könnte so aussehen:

- **Lektion 1:** Datensätze und Graphen verstehen, erste SPARQL-Queries testen
- **Lektion 2:** erste Text-to-SPARQL-Pipeline oder ersten Prompt-Ansatz entwickeln
- **Lektion 3:** Strategie verbessern, z.B. durch Ontologie-Kontext, Few-shot oder zusätzliche NLP-Techniken
- **Lektion 4:** finale Ausführung auf dem Hidden Test-Set, Abgabe erzeugen, kurze Präsentation

Sie müssen diesen Ablauf nicht exakt übernehmen, der Gesamtumfang Ihrer Lösung soll jedoch im Rahmen von **maximal vier Lektionen** bleiben.

7. Abgabeformat

Die Abgabe erfolgt als **JSON-Datei** mit einer klar definierten Struktur. Pro Testfrage ist genau ein Objekt abzugeben.

Pflichtfelder pro Eintrag:

- `question_id`
- `graph`
- `question_de`
- `generated_sparql`
- `execution_success`
- `predicted_result`

Beispielstruktur:

```
[
  {
    "question_id": "test_super_01",
    "graph": "superhero_universe",
    "question_de": "Nenne alle Antiheld:innen.",
    "generated_sparql": "PREFIX ex: <http://example.org/> ...",
    "execution_success": true,
    "predicted_result": [
      {"name": "Catwoman"},
      {"name": "Deadpool"},
      {"name": "Harley Quinn"}
    ]
  }
]
```

Falls eine Query nicht ausgeführt werden kann, soll `execution_success` auf `false` gesetzt werden. In diesem Fall soll `predicted_result` als leere Liste gespeichert werden.

8. Bewertung

Die finale Rangliste der Gruppen basiert auf dem **mittleren F1-Score auf dem Hidden Test-Set**. Für Listenfragen wird die Güte über die Resultate gemessen:

$$Precision = \frac{|R_{pred} \cap R_{gold}|}{|R_{pred}|}, \quad Recall = \frac{|R_{pred} \cap R_{gold}|}{|R_{gold}|}$$
$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

Dabei gilt:

- R_{pred} = vom System erzeugte Ergebnismenge
- R_{gold} = Goldstandard-Ergebnismenge

Die Bewertung erfolgt **zentral durch die Lehrperson** mit einem einheitlichen Evaluationsskript. Die Gruppen dürfen ihr System lokal auf dem Dev-Set testen, die offizielle Rangliste wird jedoch ausschliesslich mit der zentralen Auswertung bestimmt.

Mögliche zusätzliche Kennzahlen:

- Execution Rate,
- F1 getrennt nach Graph,
- F1 nach Schwierigkeitsgrad.

Tie-Breaker bei gleichem F1-Score:

- höhere Execution Rate,
- höherer F1-Score auf schwierigen Fragen,
- bessere Leistung über beide Graphen hinweg.

9. Weitere Abgabebestandteile

Neben der JSON-Datei reichen Sie ein:

- den reproduzierbaren Code Ihrer Lösung,
- die generierten SPARQL-Queries,
- die vorhergesagten Resultate,
- sowie eine sehr kurze Präsentation Ihrer Strategie.

Die Präsentation kann als **Poster**, **einem Slide** oder ein anderer sehr kurzer visueller Überblick erfolgen. Sie soll knapp zeigen:

- Grundidee der Lösung,
- Prompt- oder Pipeline-Design,
- verwendete Modelle und Methoden,
- wichtigste Beobachtungen,
- eine Stärke und eine Schwäche des Verfahrens.

Ein schriftlicher Bericht ist **nicht erforderlich**.

10. Challenge

Die Aufgabe wird als kleine Challenge durchgeführt. Die Gruppe mit dem höchsten mittleren **F1-Score auf dem Hidden Test-Set** gewinnt. Die konkrete Form der Auszeichnung wird im Unterricht bekanntgegeben.

11. Reflexion

Reflektieren Sie in Ihrer Präsentation oder im Gespräch insbesondere folgende Punkte:

- Welche Arten von Fragen funktionieren gut?
- Wo macht Ihr System typische Fehler?
- Welche Rolle spielen Ontologie-Kontext, Prompting oder zusätzliche NLP-Techniken?
- Wie könnten Sie Ihr Verfahren mit mehr Zeit weiter verbessern?